

뉴스 선별 엔진

일 400건 기사 중 필수 뉴스를 저비용으로 골라 4개 포맷(레터·팟캐스트·웹툰·영상)으로 자동 발행하는 파이프라인 설계안. 이번 대화에서 확정된 수치와 구조를 그대로 정리했다.

35건 일 목표 발행량	6회 일 분류 실행 횟수	Sonnet 5 분류 모델	\$860-1,600 월 예상 총비용
------------------------	-------------------------	--------------------------	--------------------------------

01 목표와 격차

기존 로드맵 목표는 일 400건 기사 중 35~40건을 저비용으로 추출해 4포맷으로 리라이팅하는 것. 지금까지 실제 가동 중인 자동화는 `frontpage_auto` (지면 1면 전용, 1일 1회, 5건/일)만으로 목표 대비 약 7분의 1 수준이었다. 이번 설계는 그 격차를 메우는 신규 분류 단계(Step1)와, 이미 있는 "지면 특별 코너" 4탭 로직의 재설계를 다룬다.

02 전체 흐름

daily-xml (S3)

하루 종일 누적 갱신



회차 실행

08 · 12 · 15 · 18 · 21 · 23시 (KST)



seen 테이블 조회

이미 처리된 key는 후보에서 제외 — GetItem, 델타만 통과



규칙 기반 사전필터

중복게재 탐지 + 최소 길이 미달 제외 (무비용)



지면 특별코너 4탭

전체·증권·산업·시그널 — 각 후보군 top-4 채점, 즉시 seen 기록(16건)



일반 필수뉴스 분류

Sonnet 5 · 제목+부제+리드 200자 · 남은 후보만



종합점수 ≥ 7.0 ?

아니오

seen 기록만, 발행 없음

예

Step2: 레터·팟캐스트·웹툰·영상 4포맷 변환




발행

S3 업로드 + DynamoDB write + CDN revalidate

기사 단위로 실패를 격리한다 — 한 기사의 변환 실패가 나머지를 막지 않는다(기존 `frontpage_auto`와 동일 원칙).

03 실행 스케줄 — 근거 데이터

2026-08-21 daily-xml 실측(361건) 기준 시간대별 게재량. 00~05시는 거의 죽은 시간대, 10시·17시에 뚜렷한 피크(조간·석간 마감분 게재).



확정 스케줄

회차	시각(KST)	목적
1	08:00	전일 야간~새벽 게재분 회수
2	12:00	오전 피크(10시대) 반영
3	15:00	오후 초반분
4	18:00	오후 피크(17시대) 반영
5	21:00	저녁분
6	23:00	당일 마감분 최종 회수

매 회차는 직전 실행 이후 신규 기사만 처리한다(델타 방식) — 같은 기사가 두 번 모델에 들어가지 않는다.

04 분류 입력 범위 — 비용 대 품질

본문 전체를 읽을 필요는 없다고 판단 — 한국어 기사는 역피라미드 구조라 제목+부제+리드 200자에 핵심 사실이 대부분 담긴다. 선정된 기사는 어차피 Step2에서 본문 전체를 다시 읽으므로 정보 손실도 없다.

입력 범위	건당 글자	일 총 글자	월비용 (SONNET 5)
제목+부제만	81자	29,367자	~\$4
제목+부제+리드 200자 — 채택	278자	100,214자	~\$10
본문 전체	1,225자	442,299자	~\$41

2026-08-21 daily-xml 361건 실측치 기준. 토큰 환산은 한국어 약 1.5토큰/자 가정.

05 모델 — Bedrock Claude Sonnet 5

모델	입력 / MTOK	출력 / MTOK	비고
Haiku 4.5	\$1	\$5	최저가, 다차원 판단엔 다소 약함
Sonnet 5 — 채택	\$2	\$10	Sonnet 4.6보다 저렴하면서 최신
Sonnet 4.6	\$3	\$15	Sonnet 5보다 비쌈 — 채택 안 함
Opus 4.8	\$5	\$25	분류 단계엔 과함

계정 내 `us.anthropic.claude-sonnet-5` 활성화 확인 완료. 선정 기준: 판단 품질 대비 비용 최적 — Sonnet 5는 이전 세대보다 저렴하면서 더 신뢰할 수 있는 판단을 제공한다.

06 사전필터 & 선별 기준

규칙 기반 사전필터 (무비용)

- 동일 사안 중복게재 탐지 — 제목 유사도 기반, 1건만 남김
- 최소 본문 길이 미달 기사 제외 (사진 캡션급)
- 카테고리 블록리스트는 채택하지 않음 — 실측 결과 스포츠·사회 등에도 폭넓게 중요한 기사가 섞여 있어 카테고리만으로는 걸러지지 않음

일반 필수뉴스 판정 (Sonnet 5)

- 다차원 가중 스코어링 — 파급력·시의성·사실/데이터 밀도(홍보성 배제)·정책·제도 변화·이례성
- 절대 기준선(예: 종합점수 ≥ 7.0) 통과 시 즉시 발행 — 하루치 전체를 모아 상대 순위(top-N)를 매기지 않음. 이렇게 해야 오전에 뽑힌 기사가 발행까지 지연되지 않는다
- 환각 방지 가드 포함 — 원문에 없는 내용을 스코어링 근거로 쓰지 않는다는 규칙 명시
- 35건/일은 고정 쿼터가 아니라 기준선이 수렴하는 평균 목표 — 뉴스가 많은 날은 더, 적은 날은 덜 발행됨. 초기 1~2주 실제 발행량을 보며 기준선 보정 필요

설계 근거 — 참고했으나 그대로 쓰지 않은 것

서울경제 프리즘(8유형 독자 큐레이션) 프로젝트의 실제 프로덕션 코드를 조사 — **재사용한 것**: 저비용 규칙 필터를 먼저 태우고 소수의 LLM 콜로 마무리하는 구조, 다차원 가중 스코어링 방식, 환각 방지 가

드. 버린 것: 페르소나별 개별 프롬프트 내용(투자자 특화 기준), 본문 전체를 매번 읽는 방식(프리즘은 원래 8개 페르소나×본문 전체라 우리 목적엔 과함).

07 지면 특별코너 4탭 재설계

기존 위젯(전체·증권·산업·시그널)의 문제: 카테고리 매칭 자체는 정확했지만 개수 제한이 없어 들쭉날쭉했다(실측: 증권 48건, 산업 41건, 시그널 6건 후보 전부 노출). 각 탭 **정확히 4건, 중요도 순으로** 통일한다.

탭	추출 근거(태그)	8/21 후보 수	순위 기준
전체(지면1면)	<code>paperNumber == "1"</code>	5건	TOP 배치 우선
증권	<code>category == "증권"</code>	48건	Sonnet 5 중요도 채점
산업	<code>category == "산업"</code>	41건	Sonnet 5 중요도 채점
시그널	<code>category == "Signal"</code>	6건	Sonnet 5 중요도 채점

인쇄면 마스트헤드("Market & signal" 등)는 XML에 태그가 없어 프로그램적으로 접근 불가 확인 — 콘텐츠 카테고리 태그로 대체.

중복 방지 순서

매 회차: 4탭 top-4(16건) 먼저 선정 → 즉시 seen 테이블 기록 → 그다음 일반 분류 실행. 일반 분류는 seen에 있는 기사를 애초에 후보에서 제외하므로, 4탭에 뽑힌 기사가 일반 분류에 중복 등장하지 않는다.

08 비용 종합

항목	기준	월 예상
Step1 분류(Sonnet 5)	일 6회, ~150K 토큰/일	~\$10
Step2 4포맷 변환	기존 5건/일=\$120-225 기준 → 35건/일 환산	\$840-1,575

항목	기준	월 예상
Fargate 컴퓨터	기존 \$1-2 → 물량 7배 환산	~\$10
합계		~\$860-1,600

Step2 단가는 기존 지면1면 실측 비용을 선형 환산한 추정치 — 실제 가동 후 재검증 필요.

09 미해결 이슈

이슈 A - 4탭 재계산 시점

지면 특별코너 4탭은 상대 순위(top-4)라, 회차마다 후보 풀이 계속 자라면 08시에 뽑힌 4건이 18시엔 더 나은 기사에 밀릴 수 있다. 이미 발행한 걸 되돌릴 순 없는데, 재순위를 어떻게 반영할지 미정 — 예: "이미 발행된 건 유지하고 남은 자리만 재경쟁" 같은 규칙이 필요해 보임.

이슈 B - 기존 FRONTPAGE_AUTO와의 관계

지면1면은 이미 `frontpage_auto` 가 1일 1회(07:00) 처리 중인 기능이다. 이번 설계대로면 같은 기능을 이 새 파이프라인이 6회/일로 다시 흡수하게 되는데, 기존 `frontpage_auto`를 대체(폐기)할지, 병행할지 결정이 필요하다. 병행 시 같은 기사를 두 파이프라인이 각자 발행할 위험이 있어, 대체 쪽을 권장하지만 확정은 아님.

10 결정 로그

볼륨 35건/일 (특별 4탭 16건 포함 총량, 별도 추가 아님)

모델 Bedrock Claude Sonnet 5 (us.anthropic.claude-sonnet-5)

입력 범위 제목 + 부제 + 리드 200자 (본문 전체 미사용)

선별 방식 절대 기준선 통과 시 즉시 발행 (일 단위 상대 랭킹 아님)

카테고리 균형	강제하지 않음
사전필터	중복게재 탐지 + 최소 길이 (규칙 기반, 무비용)
중복 방지	key 기반 seen 테이블, GetItem 조회 (Scan 아님)
스케줄	08 · 12 · 15 · 18 · 21 · 23시 KST, 델타 처리
4탭 근거	paperNumber(1면) + category(증권/산업/시그널), 각 top-4